RAPPORT PREDICTION DU RISQUE D'ABANDON SCOLAIRE

1. INTRODUCTION

L'abandon scolaire est un enjeu majeur pour les systèmes éducatifs, car il impacte directement la réussite académique et l'insertion professionnelle des étudiants. Afin d'anticiper problème, il est essentiel de mettre en place des outils capable d'identifier les étudiants susceptibles d'abandonner.

Dans ce projet, nous proposons de développer un modèle de Machine Learning permettant de prédire le risque d'abandon scolaire à partir des données académiques et comportementales collectées.

2. COMPREHENSION DU PROBLEME POSE

Le problème étudié est une classification binaire supervisée :

- 0 : étudiant sans risque d'abandon
- 1 : étudiants avec risque d'abandon

Il s'agit ici pour nous de :

-Identifier les étudiants en difficulté

-Permettre la mise en place d'action préventives

-Améliorer la réussite scolaire (grâce aux résultats obtenus)

La variable cible est dropout_risk, elle a été déterminée selon plusieurs critères liés à la performance académique et au comportement de l'étudiant.

3. DESCRIPTION DE LA BASE DE DONNEES

La base de données mise à disposition contient des informations sur les étudiants, notamment :

- Age : âge de l'étudiant
- Gender : sexe

- Average_grade : moyenne générale
- Absenteeism_rate : taux d'absentéisme
- Internet_access : accès à internet
- Study_time_hours : temps d'étude
- Extra_activities : activitées extrascolaire
- Dropout_risk : risque d'abandon (variable cible)

Ces variables permettent de mobiliser le comportement académique et social des étudiants. :

4. PRETAITEMENT DES DONNEES

Avant la modélisation, plusieurs étapes de nettoyage et transformation ont été réalisées :

- Encodage

Les variables qualitatives ou catégorielles ont été transformées en variables numériques

- Vérification des données

Une inspection des données a été effectuée pour vérifier leur cohérence.

5. ANALYSE EXPLORATOIRE DES DONNEES

L'analyse exploratoire des données (EDA) a permis de mieux comprendre les relations entre les variables.

- Histogramme

Les distributions montrent une variation des notes et du temps d'étude, ce qui permet de voir les différents profils d'étudiants.

- Matrice de corrélation

L'analyse des corrélations met en évidence que :

-la moyenne générale est négativement corrélée au risque d'abandon

-le taux d'absentéisme est positivement corrélé

-le temps d'étude réduit le risque

- Boxplot

Les étudiants à risque présentent globalement des moyennes plus faibles.

D'où la pertinence des variables utilisées pour notre étude.

6. FEATURE ENGINEERING

Une nouvelle variable appelée **vulnerability_score** (score de vulnérabilité) a été introduite afin de synthétiser plusieurs facteurs de risque.

Cette variable permet d'améliorer la capacité du modèle à détecter les étudiants en difficulté.

7. MODELISATION

Plusieurs algorithmes de **Machine Learnig** ont été testés :

-Random Forest

-Gradient Boosting

-Regression logistique

-Support Vector Machine (SVM)

Les données ont été séparées en

- **80% pour l'entrainement**
- **20% pour le test**

8. EVALUATION DES MODELES

Les performances ont été évaluées à l'aide des métriques suivantes :

- Accurancy
- AUC-ROC
- Matrice de confusion

Les résultats obtenus montrent que tous les modèles testés présentent des performances très élevées :

Accurancy = 1.0000

AUC-ROC = 1.0000

Le modèle Random Forest a été retenu comme le meilleur modèle.

9. VALIDATION CROISEE

Une validation croisée (10-folds) a été réalisée afin de garantir la robustesse des résultats. Les scores obtenus confirment la stabilité des modèles, avec une performance constante.

10. COMMENTAIRE

Les résultats obtenus montrent des performances parfaites (100%), ce qui peut s'expliquer par :

- La structure simplifiée de la base de données
- La présence de règles déterministes dans la variable cible
- La forte corrélation entre certaines variables

11. CONCLUSION

Ce projet a permis de mettre en place un modèle de prédiction du risque d'abandon scolaire en suivant un pipeline complet de **Data Science**